Análisis exploratorio y documentación reproducible del BioProject: PRJNA268110

Elizabeth Jiménez Meráz

2026-10-10

Table of contents

1. Introducción: **2**
Contexto biológico y experimental: . . . 2
Las fuentes consultadas fueron: . . . 2
Descripción del BioProject: . . . 2
Objetivo del estudio: . . . 2
Pregunta biológica que el grupo buscaba responder : . . . 3

2. Exploración del BioProject y sus datos: **3**

3. Descarga y exploración de las secuencias: **4**
Entrar al cluster ken: . . . 4
Descargar y descomprimir secuencias: . . . 4
Mostrar una parte de alguna de las lecturas crudas, y explicar qué representa cada una de las cuatro líneas: . . . 7

4. Cuantificación y exploración básica: **7**
Gráfico del reporte de Fastqc: . . . 8

5. Genoma ensamblado del organismo: **10**
Descarga del genoma: . . . 10
Respondiendo sobre el genoma: . . . 11

1. Introducción:

Contexto biológico y experimental:

Las fuentes consultadas fueron:

- BioProject PRJNA268110 en NCBI.
- Página de SRA Links para este BioProject
- SRA Run Selector para este BioProject con la información de todas los SRA.

Descripción del BioProject:

El organismo estudiado es *Saccharomyces cerevisiae* (levadura de cerveza) con Taxonomy ID: 4932. Se utilizaron dos cepas según el Run Selector, que se especifican en las columnas *strain* y *genotype*:

- **WFA72**: silvestre (*MEC1*).
- **WFA73**: mutante *mec1*, deficiente en el punto de control de replicación (checkpoint).

La Institución o grupo responsable de este estudio fue el Laboratorio de Wenyi Feng del Departmento of Bioquímica y Biología Molecular de la SUNY Upstate Medical University (EE. UU.).

La publicación asociada es: Hoffman EA *et al.*, "Break-seq reveals hydroxyurea-induced chromosome fragility as a result of unscheduled conflict between DNA replication and transcription", *Genome Research* 2015; 25(3):402–412.

Las fechas aproximadas:

- Para registro del BioProject y creación de las corridas en SRA: 20 de noviembre de 2014
- Para la publicación del artículo: marzo de 2015.

Objetivo del estudio:

El objetivo general del estudio era medir el transcriptoma por RNA-seq durante y después de una exposición a hidroxiurea (HU) en células silvestres y mutadas *mec1*. Según la sección *Navigate Up*, este proyecto forma parte de un estudio mayor que combina RNA-seq con Break-Seq, una técnica para mapear rupturas de doble cadena (DSBs). El RNA-seq sirve para identificar qué genes induce la HU y comparar sus posiciones con los sitios de ruptura cromosómica.

Pregunta biológica que el grupo buscaba responder :

El grupo ya había observado que, sin un checkpoint funcional (*mec1*), los cromosomas se rompen en las horquillas de replicación tras la exposición a HU. Aquí querían saber por qué esas rupturas no ocurren al azar: ¿la fragilidad cromosómica inducida por HU se debe a que las horquillas detenidas, con regiones de ssDNA, chocan con genes que la propia HU activa transcripcionalmente?

El RNA-seq permite identificar qué genes se inducen en cada genotipo y condición, para compararlos con el mapa de DSBs obtenido por Break-Seq. Según la descripción del proyecto:

- En células silvestres, las rupturas se concentraron en genes de factores de transcripción de respuesta a estrés.
- En *mec1*, se concentraron en genes de transportadores, muchos de ellos regulados por esos mismos factores.

Los autores proponen que el conflicto entre replicación y transcripción explicaría por qué distintos inhibidores de la replicación generan patrones diferentes de rupturas cromosómicas.

2. Exploración del BioProject y sus datos:

A continuación se presenta una tabla donde se organizan datos de los BioSample(s) asociados y los SRA Run(s) correspondientes.

Biosample	SRA	Exp.	SRA Run	Tipo de secuenciación	Paired/Single
SAMN03203063	SRS749175	SRX764815	SRR16584541	ILLUMINA (Illumina MiSeq)	Paired
SAMN03203064	SRS749174	SRX764816	SRR16584551	ILLUMINA (Illumina MiSeq)	Paired
SAMN03203065	SRS749176	SRX764817	SRR16584561	ILLUMINA (Illumina MiSeq)	Paired
SAMN03203053	SRS749177	SRX764818	SRR16584571	ILLUMINA (Illumina MiSeq)	Paired
SAMN03203062	SRS749178	SRX764819	SRR16584581	ILLUMINA (Illumina MiSeq)	Paired
SAMN03203059	SRS749179	SRX764820	SRR16584591	ILLUMINA (Illumina MiSeq)	Paired
SAMN03203067	SRS749181	SRX764821	SRR16584601	ILLUMINA (Illumina MiSeq)	Paired
SAMN03203068	SRS749180	SRX764822	SRR16584611	ILLUMINA (Illumina MiSeq)	Paired

La diferencia entre BioProject, BioSample, SRA Experiment y SRA Run radica en que son 4 niveles jerárquicos distintos:

El BioProject describe el proyecto de investigación completo: el objetivo, el organismo, la institución y las publicaciones. Agrupa todos los datos de ese estudio, sin importar su tipo.

La BioSample describe el material biológico de origen: qué organismo, cepa, genotipo y condición. Responde a la pregunta *¿de dónde se extrajo el ácido nucleico?* No contiene aún secuencias.

El SRA Experiment describe cómo se preparó y secuenció una muestra: la biblioteca (estrategia, selección, *layout* single o paired) y el instrumento. Responde a *¿qué se hizo con la muestra?*

SRA Run es el archivo de datos en sí: las lecturas producidas por una corrida del secuenciador para un experimento. Es lo que se decarga (FASTQ) y analiza.

Básicamente, existe un solo BioProject donde encontramos la información de varias BioSample (organismos de dónde se obtuvo el ácido nucléico). Por cada BioSample tenemos indicado uno o más SRA Experiment (experimentos de secuenciación), y finalmente por cada SRA Experiment podemos tener uno o más SRA Run (archivos de lecturas).

3. Descarga y exploración de las secuencias:

Entrar al cluster ken:

Entrar al cluster ken:

```
# ssh -Y username@ken.lavis.unam.mx
```

Salir del espacio de login en el cluster:

```
# cd /mnt/data/bioinfo1/username
```

Entrar a una sesión interactiva

```
# srun --export=ALL --x11 --pty bash
```

Descargar y descomprimir secuencias:

Cargar la herramienta sra 3.1.1 para descargar las secuencias crudas del BioProject.

```
# module load sra/3.1.1
```

Descargar las secuencias crudas del BioProject:

```
# prefetch NOMBRE_SRA
```

- Nota: Nombres de los SRA:

SRR1658454

SRR1658455

SRR1658456

SRR1658457

SRR1658458

SRR1658459

SRR1658460

SRR1658461

Descomprimir y separar las secuencias en caso de que exista Forward y Reverse.

```
# fasterq-dump NOMBRE_SRA
```

Número de archivos descargados: 16 archivos .fastq, dos por cada SRA.

Tamaño de cada archivo (Mb o Gb):

Archivo	Tamaño
SRR1658454_1.fastq y SRR1658454_2.fastq	741Mb
SRR1658455_1.fastq y SRR1658455_2.fastq	449Mb
SRR1658456_1.fastq y SRR1658456_2.fastq	522Mb
SRR1658457_1.fastq y SRR1658457_2.fastq	960Mb
SRR1658458_1.fastq y SRR1658458_2.fastq	1.3Gb
SRR1658459_1.fastq y SRR1658459_2.fastq	870Mb

Archivo	Tamaño
SRR1658460_1.fastq y SRR1658460_2.fastq	715Mb
SRR1658461_1.fastq y SRR1658461_2.fastq	1.1Gb

- Número de secuencias:

```
# $ grep -c @SRR *_1.fastq
```

Archivo	Número de secuencias
SRR1658454_1.fastq y SRR1658454_2.fastq	3438388
SRR1658455_1.fastq y SRR1658455_2.fastq	2090805
SRR1658456_1.fastq y SRR1658456_2.fastq	2428934
SRR1658457_1.fastq y SRR1658457_2.fastq	4452257
SRR1658458_1.fastq y SRR1658458_2.fastq	6080904
SRR1658459_1.fastq y SRR1658459_2.fastq	4037197
SRR1658460_1.fastq y SRR1658460_2.fastq	3317701
SRR1658461_1.fastq y SRR1658461_2.fastq	4961938

- Longitud promedio de las lecturas: Aproximadamente 75bp
- Identificar si las lecturas son paired-end o single-end:
  - Las lecturas son paired-end, esto podemos observarlo en la tabla del Run Selector y también porque al descomprimir las secuencias con $ fasterq-dump NOMBRE_SRA obtenemos archivos *_1 y* _2, de los cuales uno es Forward y otro es Reverse.

Mostrar una parte de alguna de las lecturas crudas, y explicar qué representa cada una de las cuatro líneas:

```
[kjimenez@node01 kjimenez]$ head SRR1658454_1.fastq
@SRR1658454.1 1 length=75
CGGGAATTCATCATCAGTCCTTCCCACTAAGTAAACAAGGTGTCTTCATCTCTCAAATACTCACCAATATCTGCT
+SRR1658454.1 1 length=75
668--+CFF9FGGGGGGGGGGGGGGGGGGGGFFDFFGFFG8CFFFF9FFFGFGFAAFFFDF,CFC8F,CCC,<C
@SRR1658454.2 2 length=75
CCCTTTTATTTTATTTTGCTGCAAATATAATATACACAACCCTAATTACATTGAAACTTGACATTATGTCTTTCC
+SRR1658454.2 2 length=75
688BCFG,CFGG9FEGG<FGGGGGGGFGGFGGFCC,C<CBF,;,,<E,<,CE<,,,;EC,,;<F,,C,,6;,,;,
@SRR1658454.3 3 length=73
CTCTGTATTTTCTAGCCTTGATGTATTTCTTCATGTCCCTGACCACTGCCTTGACATAAGTATCAGTGTTTGT
[kjimenez@node01 kjimenez]$
```

El significado de las 4 líneas (en orden) es:

Línea	Inicio de la línea	Significado
1°	@SRR …	ID de la lectura.
2°	Secuencia de nt (T,A,C,G)	Es la secuencia de nucleótidos de esa lectura.
3°	+…	Es un separador entre la secuencia de la lectura y los puntajes de calidad.
4°	Letras y símbolos	Contiene los puntajes de calidad (*Phred scores*) de cada base de la línea 2, codificados en caracteres ASCII.

4. Cuantificación y exploración básica:

Correr el Fastqc para las secuencias, y colocar un gráfico de reporte de Fastqc de un archivo fastq.

Cargar la herramienta fastqc/0.11.3

```
# module load fastqc/0.11.3
```

Crear los html para correr el fastqc

Crear solo el html para el SRR1658454_1.fastq

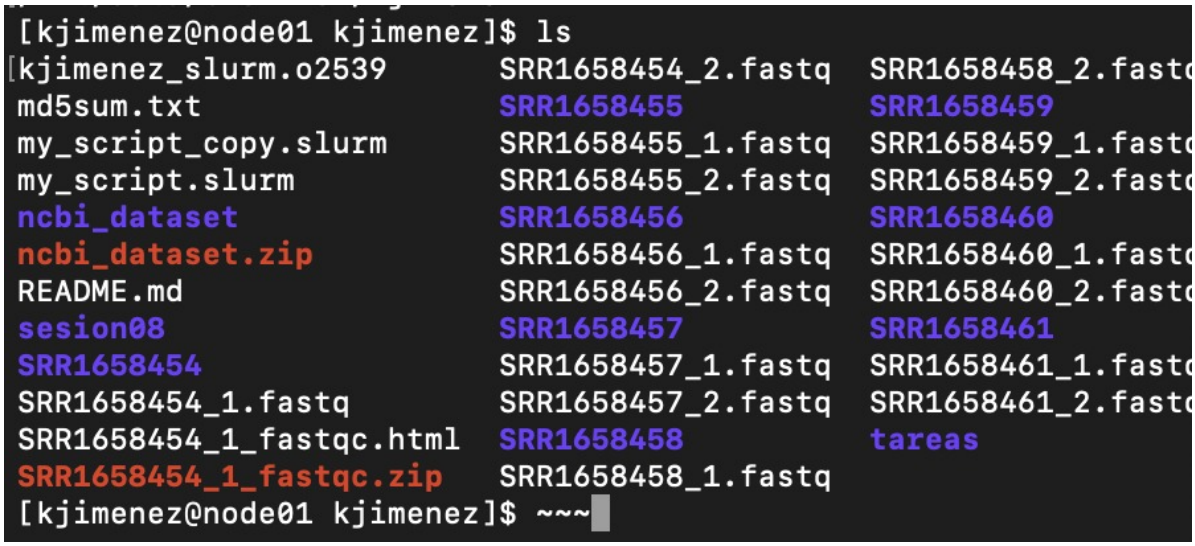
```
# fastqc SRR1658454_1.fastq
```

Correr el fastqc

```
# firefox SRR1658454_1_fastqc.html
```

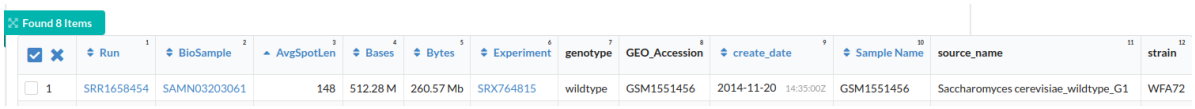
Gráfico del reporte de Fastqc:

- Nota: no me fue posible abrir el reporte de Fastqc (archivo html), aunque como se ve en la captura, sí lo creé:

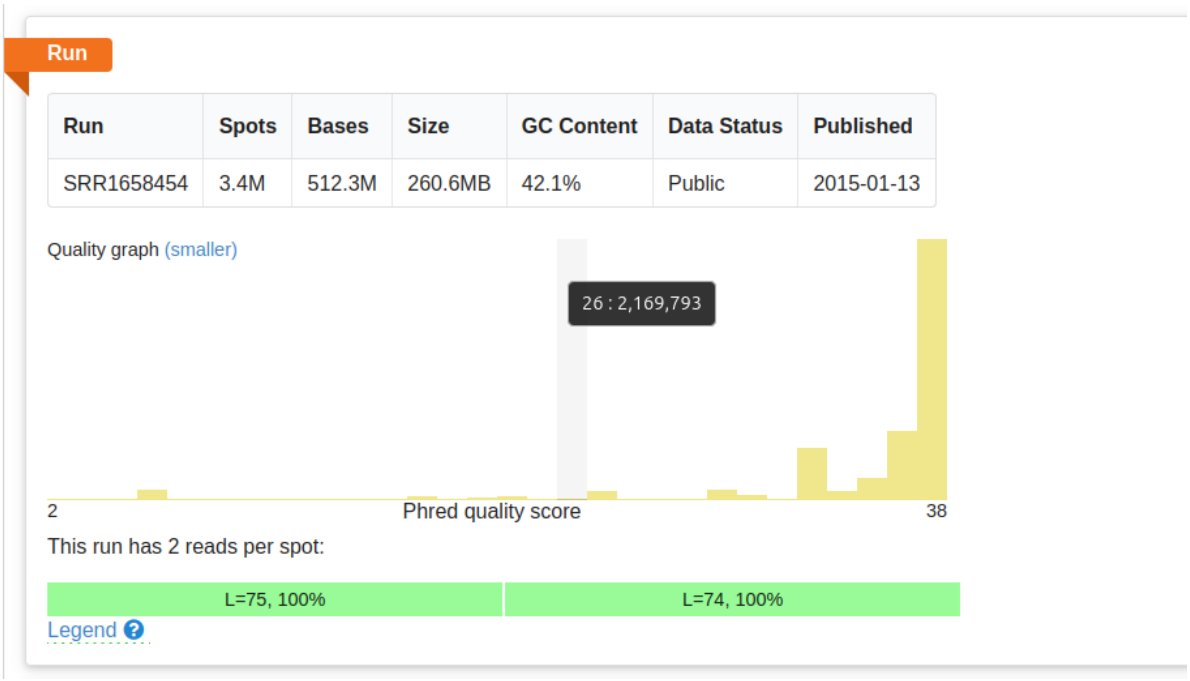


Por lo tanto, lo busqué en NCBI:

- Desde la página de Run Selector, entré al link del Run correspondiente al archivo fastqc que había convertido en html previamente.



Y ahí encontré el reporte disponible en NCBI:



- Número total de reads:

```
# grep '^@SRR' SRR1658454_1.fastq | wc -l
```

Este comando nos arroja que el archivo SRR1658454_1.fastq tiene 3438388 lecturas.

- Longitud de las lecturas:

```
# grep '^@SRR' SRR1658454_1.fastq | cut -d' ' -f3 | sort | uniq -c
```

Este comando nos deja ver que las lecturas de este archivo tienen un longitud de entre 35 y 75 bp, donde la mayoría de las secuencias tienen entre 75 y 74 bp:

```
[kjimenez@node01 kjimenez]$ grep '^@SRR' SRR1658454_1.fastq | cut -d' ' -f3 | sort | uniq -c
     13 length=35
      7 length=36
      5 length=37
      5 length=38
      4 length=39
     10 length=40
      7 length=41
     12 length=42
     20 length=43
     23 length=44
     21 length=45
     33 length=46
     34 length=47
     44 length=48
     56 length=49
     59 length=50
     53 length=51
     77 length=52
     78 length=53
     91 length=54
    134 length=55
    129 length=56
    119 length=57
    161 length=58
    137 length=59
    180 length=60
    249 length=61
    266 length=62
    300 length=63
    317 length=64
    419 length=65
    377 length=66
    449 length=67
    490 length=68
    679 length=69
   3655 length=70
  16076 length=71
  64400 length=72
 203825 length=73
 873579 length=74
2271795 length=75
[kjimenez@node01 kjimenez]$
```

5. Genoma ensamblado del organismo:

Descarga del genoma:

Ya en el cluster ken y en una sesión interactiva:

Cargar la herramienta **ncbi-datasets/18.16:**

```
# module load ncbi-datasets/18.16
```

Descargar SOLO el genoma de referencia:

```
# datasets download genome accession CF_000146045.2 --include genome
```

Respondiendo sobre el genoma:

El assembly/genoma de referencia o ensamblado disponible para *Saccharomyces cerevisiae* es el R64, con ID para GeneBank: GCA_000146045.2 y ID para RefSeq: GCF_000146045.2

Tamaño total del genoma: 12.1Mb

Número de contigs/scaffolds o cromosomas, según corresponda:

- Contigs: 16
- Scaffolds: 16
- Cromosomas: 16